

# Временные ряды - 1


Елена Кантонистова

# Занятие 1

Статистические модели прогнозирования

# ВРЕМЕННОЙ РЯД

*Временной ряд* – это последовательность значений, описывающих протекающий во времени процесс, измеренных в последовательные моменты времени, обычно через равные промежутки.




# ЗАДАЧА ПРОГНОЗИРОВАНИЯ

$y_0, y_1, \dots, y_t, \dots$  - временной ряд,  $y_i \in \mathbb{R}$ .

Задача: построить функцию


$$\hat{y}_{t+d}(w) = a_{t,d}(y_1, \dots, y_t; w)$$

- $d = 1, \dots, D$ , где  $D$  – горизонт прогнозирования
- $w$  – вектор параметров модели




# КОМПОНЕНТЫ ВРЕМЕННОГО РЯДА

- *Тренд* – плавное долгосрочное изменение уровня ряда
- *Сезонность* – циклические изменения уровня ряда с постоянным периодом
- *Циклы* – изменения уровня ряда с переменным периодом (цикл жизни товара, экономические волны, периоды солнечной активности)
- *Ошибка (шум)* – непрогнозируемая случайная компонента ряда




# ЦИКЛЫ И СЕЗОННОСТЬ

Сезонность:



Цикл:



# СТАЦИОНАРНОСТЬ


***Стационарный временной ряд*** - это временной ряд, у которого статистические свойства не меняются со временем.

Формально, стационарный временной ряд должен удовлетворять следующим условиям:


- *Постоянное среднее значение*: среднее значение ряда должно быть постоянным и не зависеть от времени. Это означает, что в разные моменты времени ряд не должен демонстрировать систематический тренд вверх или вниз.
- *Постоянная вариация*: дисперсия ряда должна быть постоянной и не зависеть от времени. Это означает, что в разные моменты времени амплитуда колебаний ряда не должна изменяться.
- *Некоррелированность*: корреляция между значениями ряда на разных временных отрезках должна быть незначительной или отсутствовать вовсе. Это означает, что отсутствуют систематические зависимости или паттерны, которые повторяются во времени.

# СТАЦИОНАРНОСТЬ

**Stationary Time Series**



**Non-stationary Time Series**





# СТАЦИОНАРНОСТЬ

Ряд  $y_1, \dots, y_T$  **стационарен**, если для любого  $s$  распределение  $y_t, \dots, y_{t+s}$  не зависит от  $t$ , то есть его свойства не зависят от времени.

- тренд  $\Rightarrow$  нестационарность
- сезонность  $\Rightarrow$  нестационарность
- цикл — заранее неизвестно


*По стационарному ряду просто построить прогноз, так как мы полагаем, что его будущие статистические характеристики не будут отличаться от наблюдаемых текущих.*

Для проверки стационарности ряда можно использовать критерий Дики-Фуллера.

# ЕДИНИЧНЫЙ КОРЕНЬ


Рассмотрим модель временного ряда  $X_t = \rho \cdot X_{t-1} + \varepsilon_t$ ,  
где  $\varepsilon_t$  - ошибка, не зависящая от значений временного ряда.

**Определение.** Если  $\rho = 1$ , то говорят, что ряд имеет  
единичный корень.




# ЕДИНИЧНЫЙ КОРЕНЬ


Rho 0.6  
Dickey-Fuller p-value: 0.0



Rho 0.9  
Dickey-Fuller p-value: 0.0



# ЕДИНИЧНЫЙ КОРЕНЬ




Видно, что при  $\rho = 1$  процесс не возвращается к своему среднему, а значит, не является стационарным.

# ПРОВЕРКА СТАЦИОНАРНОСТИ РЯДА

Проверку стационарности ряда можно осуществлять с помощью критерия Дики-Фуллера.

- Критерий Дики-Фуллера проверяет гипотезу  $\rho = 1$ .

# ПРИМЕРЫ ВРЕМЕННЫХ РЯДОВ




# ПРАКТИКА-1

- Time series intro
- Time series intro (bonus)

# СТАТИСТИЧЕСКИЕ МЕТОДЫ ПРОГНОЗА ВРЕМЕННЫХ РЯДОВ

- Этот подход основан на том, что стационарный временной ряд прогнозировать несложно, поэтому общая идея такая:
- Приводим ряд к стационарному
- С помощью линейной регрессии прогнозируем стационарный временной ряд
- Применяем обратные преобразования к прогнозу





# МЕТОДЫ ИЗБАВЛЕНИЯ ОТ НЕСТАЦИОНАРНОСТИ

## 1. Стабилизация дисперсии

- для рядов с монотонно меняющейся дисперсией можно использовать стабилизирующее **преобразование Бокса-Кокса** ( $\lambda$  – параметр метода):


$$y'_t = \begin{cases} \ln y_t, \lambda = 0 \\ \frac{y_t^\lambda - 1}{\lambda}, \lambda \neq 0 \end{cases}$$

- логарифмирование – частный случай



*Параметр  $\lambda$  подбирается так, чтобы сделать дисперсию как можно более однородной.*

# СТАБИЛИЗАЦИЯ ДИСПЕРСИИ (ПРИМЕР)

Исходный ряд:



Преобразование Бокса-Кокса с  $\lambda = 0$  (слева) и  $\lambda = 0.3$  (справа):




# МЕТОДЫ ИЗБАВЛЕНИЯ ОТ НЕСТАЦИОНАРНОСТИ

2. Дифференцирование – переход к попарным разностям для соседних значений ряда

$$y'_t = y_t - y_{t-1}$$

- стабилизирует среднее значение ряда, позволяет избавиться от тренда
- можно применять неоднократно





# МЕТОДЫ ИЗБАВЛЕНИЯ ОТ НЕСТАЦИОНАРНОСТИ

3. Сезонное дифференцирование – переход к попарным разностям значений в соседних сезонах

$$y'_t = y_t - y_{t-s}$$

- убирает сезонность



*Сезонное дифференцирование лучше применять в начале – возможно, после него ряд уже станет стационарным.*


# МОДЕЛИ ВРЕМЕННЫХ РЯДОВ – ЭКОНОМЕТРИЧЕСКИЙ ПОДХОД

- Модель авторегрессии  $AR(p)$ :


$$y_t = a_1 y_{t-1} + a_2 y_{t-2} + \dots + a_p y_{t-p} + \varepsilon_t,$$

$a_p \neq 0$ ,  $\varepsilon_t$  - процесс белого шума,  $E\varepsilon_t = 0$ ,  $D\varepsilon_t = \sigma_\varepsilon^2$ ,  $cov(\varepsilon_t, \varepsilon_s) = 0$ , некоррелируемый с  $y_t$ .

AR(1)



AR(2)




# МОДЕЛИ ВРЕМЕННЫХ РЯДОВ – ЭКОНОМЕТРИЧЕСКИЙ ПОДХОД

- Процесс скользящего среднего порядка  $q$  ( $MA(q)$ ):

$$y_t = \alpha + \varepsilon_t + b_1\varepsilon_{t-1} + b_2\varepsilon_{t-2} + b_q\varepsilon_{t-q},$$

$b_q \neq 0$ ,  $\varepsilon_t$  - процесс белого шума,  $E\varepsilon_t = 0$ ,  $D\varepsilon_t = \sigma_\varepsilon^2$ ,  $cov(\varepsilon_t, \varepsilon_s) = 0$ , некоррелируемый с  $y_t$ . Такой процесс всегда стационарен.



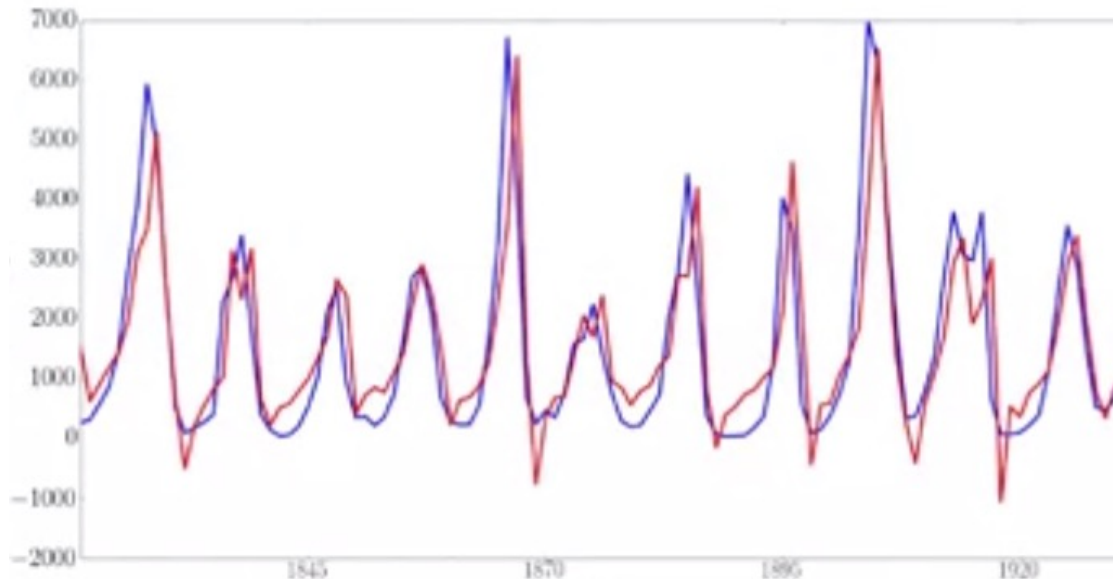
# МОДЕЛИ ВРЕМЕННЫХ РЯДОВ – ЭКОНОМЕТРИЧЕСКИЙ ПОДХОД

- Смешанный процесс авторегрессии  $ARMA(p, q)$ :

$$y_t = \alpha + a_1 y_{t-1} + \dots + a_p y_{t-p} + \varepsilon_t + b_1 \varepsilon_{t-1} + \dots + b_q \varepsilon_{t-q},$$


$$a_p, b_q \neq 0.$$

**Теорема Вольда.** Любой стационарный ряд можно приблизить моделью  $ARMA(p, q)$  сколь угодно точно.



# МОДЕЛИ ВРЕМЕННЫХ РЯДОВ – ЭКОНОМЕТРИЧЕСКИЙ ПОДХОД

- Модель  $ARIMA(p, d, q)$  - модель  $ARMA(p, q)$  для  $d$  раз продифференцированного ряда.



- Модель  $SARIMA$  – модель  $ARMA$  с учетом наличия тренда и сезонности



# АВТОКОРЕЛЛЯЦИЯ

Для анализа временного ряда очень полезно изучить автокорреляционную функцию.

- Автокорреляция - это просто корреляция временного ряда с собой же, но сдвинутым на несколько моментов времени.
- То есть, например, мы можем посчитать корреляцию между рядом

$$y_t, y_{t-1}, y_{t-2}, \dots$$

и им же, но, например, два момента времени назад:



$$y_{t-2}, y_{t-3}, y_{t-4}, \dots$$

*Большое значение коэффициента корреляции будет сигнализировать о том, что на значение ряда сегодня сильно влияет значение ряда два момента времени назад.*

# АВТОКОРЕЛЯЦИОННАЯ ФУНКЦИЯ (ACF)


Теперь, зная что такое автокорреляция, определим автокорреляционную функцию (AutoCorrelation Function, ACF):

- для каждого значения  $k = 0, 1, 2, \dots$  посчитаем корреляцию ряда в текущий момент времени и  $k$  моментов времени назад
- по оси  $x$  отложим  $k$ , по оси  $y$  - полученные значения корреляции



# ЧАСТНАЯ АВТОКОРРЕЛЯЦИЯ (РАСФ)

Когда мы говорим об автокорреляции между рядом в моментами времени  $t$  и  $t - k$ , мы считаем не чистое влияние  $y_{t-k}$  на  $y_t$ , а на самом деле совокупный эффект, с которым ряд в моменты времени  $t - k, t - k + 1, \dots, t - 1$  влияет на ряд в момент времени  $t$ .




# ЧАСТНАЯ АВТОКОРРЕЛЯЦИЯ (РАСФ)

Это не совсем то, что мы бы хотели видеть. Поэтому определяют частную (частичную) автокорреляцию – это часть корреляции между моментами времени  $t$  и  $t - k$ , которая не объясняется промежуточными корреляциями.

Если говорить точнее, то пусть

$$y_t = \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \dots + \varphi_k y_{t-k} + \varepsilon_t$$


Тогда частная корреляция между рядом в момент времени  $t$  и  $t - k$  равна  $\varphi_k$ .



# АСФ И РАСФ ДЛЯ ПОДБОРА ГИПЕРПАРАМЕТРОВ МОДЕЛИ ARMA

## Правило:

$p$  и  $q$  - число значимых лагов за период (если период/сезон есть) - то есть столбиков, выходящих за закрашенные области вокруг оси  $x$ .



Из графика можно определить кандидаты для оптимальных  $p$  и  $q$ :

- $p=1$  (по графику PACF)
- $q=1,2,3,4$  (по графику ACF).

# ПРАКТИКА-2

- Statsmodels intro
- Statsmodels ARIMA

# SARIMA

- В случае, если в ряде есть и тренд, и сезонность, то можно использовать модель **SARIMA**, которая учитывает в себе и тренд, и сезонные эффекты.
- У модели SARIMA два набора гиперпараметров:
- $order = (p, d, q)$  - те же гиперпараметры, что у ARIMA
- $seasonal\_order = (P, D, Q, S)$  - сезонные гиперпараметры

С увеличением числа гиперпараметров растет сложность их подбора. Подбирать гиперпараметры можно двумя способами:

- Анализируя графики функций ACF и PACF
- Перебором, минимизируя ошибку модели

Хорошо работает комбинация этих подходов.


# SARIMAX

- Иногда, кроме непосредственно прогнозируемого временного ряда, в данных есть другие факторы, также зависящие от времени - они называются **экзогенными факторами**. Для улучшения качества прогноза кроме самого ряда полезно учитывать экзогенные факторы.
- Модель, которая позволяет учесть эти факторы называется **SARIMAX** (Seasonal AutoRegressive Integrated Moving Average with eXogenous regressors model). В модели появляются дополнительные гиперпараметры:
- `endog` - прогнозируемый ряд
- `exog` - столбцы с экзогенными факторами.



# ПОДБОР ГИПЕРПАРАМЕТРОВ ( $P, D, Q, S$ ) ПО ГРАФИКАМ АСФ И РАСФ

- Построим графики АСФ и РАСФ для ряда уже без тренда
- Сезон  $S$  определяется по АСФ визуально - это период, через который корреляции начнут себя примерно повторять



- По графику АСФ видим, что сезон  $S=12$
- $P$  - число значимых пиков РАСФ в сезон (при сезоне  $S=12$  анализируем столбцы с номерами 12,24,36...):  $P = 1,2,3$
- $Q$  - число значимых пиков АСФ в сезон:  $Q = 1$

# ПОДБОР ГИПЕРПАРАМЕТРОВ ПЕРЕБОРОМ

Гиперпараметры  $(p,d,q)$  и  $(P,D,Q,S)$  можно найти перебором - при переборе мы минимизируем некоторую ошибку модели. Это может быть классическая **RMSE**.

- Но чаще в моделях SARIMA(X) используют **AIC/BIC** критерии для поиска оптимальных гиперпараметров.
- Простыми словами, AIC и BIC - это модификации ошибки модели с учетом ее сложности.

# ПОДБОР ГИПЕРПАРАМЕТРОВ ПЕРЕБОРОМ

- Формула для критерия Акаике (AIC):

$$AIC = -2\ln\Pi + 2k$$

- Формула для Байесовского информационного критерия (BIC):

$$BIC = -2\ln\Pi + 2k \cdot \ln n$$

$\Pi$  - правдоподобие (в классических моделях  $\ln\Pi$  часто совпадает с известными функциями потерь:  $MSE$  (регрессия) или  $\log-loss$  (классификация))

$k$  - число признаков (весов), используемых в модели (= сложность модели)

$n$  - число объектов (константа)

# СТАТИСТИЧЕСКИЕ МЕТОДЫ (ИТОГ)

Подведем итог по статистическому подходу. Он состоит в следующем:

- проверяем ряд на стационарность и в случае нестационарности приводим его к стационарному (либо самостоятельно, либо внутри готовых моделей ARIMA/SARIMA/SARIMAX)
- делаем прогноз для стационарного ряда с помощью линейной регрессии (авторегрессии)
- делаем обратные преобразования для получения прогноза для исходного ряда (либо самостоятельно, либо внутри готовых моделей ARIMA/SARIMA/SARIMAX)
- Подход дает хорошие результаты, однако требует понимание математики методов.


# ПРАКТИКА-3

- SARIMAX intro
- SARIMAX

# АДАПТИВНЫЕ МОДЕЛИ

# АДАПТИВНЫЕ МЕТОДЫ

**Адаптивные методы прогнозирования временных рядов** представляют из себя методы, цель которых заключается в построении самокорректирующихся моделей, которые способны отражать изменяющееся во времени поведение ряда.



# СКОЛЬЗЯЩЕЕ СРЕДНЕЕ

$$\hat{y}_{t+1} = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}$$


- чтобы сделать прогноз на следующий период времени, надо знать значение на текущий период (т.е. долгосрочный прогноз невозможен)

+ сглаживает данные




# СКОЛЬЗЯЩЕЕ СРЕДНЕЕ

Moving average  
window size = 24



Moving average  
window size = 168



# ЭКСПОНЕНЦИАЛЬНОЕ СКОЛЬЗЯЩЕЕ СРЕДНЕЕ

*Идея: на значение ряда в данный момент времени больше всего влияет значение в предыдущий момент времени, затем – значение в предпредыдущий момент времени и т.д (то есть более поздние данные – более важные).*

Пример:

$$EMA(t) = \frac{1}{2}p_t + \frac{1}{4}p_{t-1} + \frac{1}{8}p_{t-2} + \dots$$

# ЭКСПОНЕНЦИАЛЬНОЕ СКОЛЬЗЯЩЕЕ СРЕДНЕЕ

Пусть ряд ведет себя следующим образом:

$$y_t = l_t + \varepsilon_t,$$

- $l_t$  - некоторое медленно меняющееся во времени значение (level)
- $\varepsilon_t$  - шумовая компонента (со средним значением ноль).

Тогда прогнозировать мы должны компоненту  $l_t$ .

# ЭКСПОНЕНЦИАЛЬНОЕ СКОЛЬЗЯЩЕЕ СРЕДНЕЕ

- Простейшая регрессионная модель – константа:

$$\hat{y}_{t+d} = \hat{l}_t = l$$

Минимизируем квадратичную ошибку с весами  $\beta^i$ , убывающими в прошлое:

$$\sum_{i=0}^t \beta^i (y_{t-i} - l)^2 \rightarrow \min_c$$

Аналитическое решение (формула Надарая-Ватсона):


$$\hat{y}_{t+1} = l = \frac{\sum_{i=0}^t \beta^i y_{t-i}}{\sum_{i=0}^t \beta^i}$$

# ЭКСПОНЕНЦИАЛЬНОЕ СКОЛЬЗЯЩЕЕ СРЕДНЕЕ (ЭСС)

**Утверждение.** Модель ЭСС можно записать в виде

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha)\hat{y}_t, \alpha \in (0, 1)$$

- чем больше  $\alpha$ , тем больше вес последних точек
- чем меньше  $\alpha$ , тем сильнее сглаживание




# ЭКСПОНЕНЦИАЛЬНОЕ СКОЛЬЗЯЩЕЕ СРЕДНЕЕ (ЭСС)

Оптимальное значение  $\alpha$  подбираем по скользящему контролю:

$$Q(\alpha) = \sum_{t=t_0}^T (\hat{y}_t(\alpha) - y_t)^2 \rightarrow \min_{\alpha}$$

- при  $\alpha \in (0, 0.3)$  ряд стационарен, модель ЭСС работает
- при  $\alpha \in (0.3, 1)$  ряд нестационарен, нужна модель тренда

# МОДЕЛИ С ТРЕНДОМ И СЕЗОННОСТЬЮ



- Ряд 1 - сезонность без тренда
- Ряд 2 - линейный тренд, аддитивная сезонность
- Ряд 3 – линейный тренд, мультипликативная сезонность
- Ряд 4 – экспоненциальный тренд, мультипликативная сезонность

# МОДЕЛИ С ТРЕНДОМ И СЕЗОННОСТЬЮ

## Модель Хольта

- модель линейного тренда

$$\hat{y}_{t+d} = a_t + b_t d,$$

где  $a_t, b_t$  - адаптивные компоненты линейного тренда.

- формулы для  $a_t, b_t$ :

$$a_t = \alpha_1 y_t + (1 - \alpha_1)(a_{t-1} + b_{t-1})$$

$$b_t = \alpha_2 (a_t - a_{t-1}) + (1 - \alpha_2)b_{t-1},$$

где  $\alpha_1, \alpha_2$  - параметры сглаживания.



# МОДЕЛИ С ТРЕНДОМ И СЕЗОННОСТЬЮ

## Модель Винтерса (с аддитивной/мультипликативной сезонностью)

- модель мультипликативной сезонности периода  $s$

$$\hat{y}_{t+d} = a_t \cdot \theta_{t+(d \bmod s)-s},$$

$\theta_0, \dots, \theta_{s-1}$  - сезонный профиль периода  $s$  без тренда.

формулы для  $a_t, b_t, \theta_t$ :

$$a_t = \alpha_1(y_t/\theta_{t-s}) + (1 - \alpha_1) a_{t-1}$$

$$\theta_t = \alpha_2(y_t/a_t) + (1 - \alpha_2)\theta_{t-s},$$

где  $\alpha_1, \alpha_2$  - параметры сглаживания.

# МОДЕЛИ С ТРЕНДОМ И СЕЗОННОСТЬЮ

## Модель Хольта-Винтерса

- модель линейного тренда с аддитивной сезонностью

$$\hat{y}_{t+d} = (a_t + b_t d) + \theta_{t+(d \bmod s)-s},$$

$a_t + b_t d$  – тренд, очищенный от сезонных колебаний,

$\theta_0, \dots, \theta_{s-1}$  - сезонный профиль периода  $s$  без тренда.

формулы для  $a_t, b_t, \theta_t$ :

$$a_t = \alpha_1(y_t - \theta_{t-s}) + (1 - \alpha_1)(a_{t-1} + b_{t-1})$$

$$b_t = \alpha_2(a_t - a_{t-1}) + (1 - \alpha_2)b_{t-1}$$

$$\theta_t = \alpha_3(y_t - a_t) + (1 - \alpha_3)\theta_{t-s},$$

где  $\alpha_1, \alpha_2, \alpha_3$  - параметры сглаживания.

# МОДЕЛИ С ТРЕНДОМ И СЕЗОННОСТЬЮ

## Модель Хольта-Винтерса с аддитивным трендом и мультипликативной сезонностью

- модель мультипликативной сезонности периода  $s$  с линейным трендом

$$\hat{y}_{t+d} = (a_t + b_t d) \cdot \theta_{t+(d \bmod s)-s},$$

$a_t + b_t d$  – тренд, очищенный от сезонных колебаний,

$\theta_0, \dots, \theta_{s-1}$  – сезонный профиль периода  $s$  без тренда.

формулы для  $a_t, b_t, \theta_t$ :

$$a_t = \alpha_1(y_t/\theta_{t-s}) + (1 - \alpha_1)(a_{t-1} + b_{t-1})$$

$$b_t = \alpha_2(a_t - a_{t-1}) + (1 - \alpha_2)b_{t-1}$$

$$\theta_t = \alpha_3(y_t/a_t) + (1 - \alpha_3)\theta_{t-s},$$

где  $\alpha_1, \alpha_2, \alpha_3$  – параметры сглаживания.

# МОДЕЛИ С ТРЕНДОМ И СЕЗОННОСТЬЮ

## Модель Хольта-Винтерса с экспоненциальным трендом и мультипликативной сезонностью

- модель мультипликативной сезонности периода  $s$  с экспоненциальным трендом

$$\hat{y}_{t+d} = a_t(r_t)^d \cdot \theta_{t+(d \bmod s)-s},$$

$a_t(r_t)^d$  – тренд, очищенный от сезонных колебаний,

$\theta_0, \dots, \theta_{s-1}$  - сезонный профиль периода  $s$  без тренда.

формулы для  $a_t, b_t, \theta_t$ :

$$a_t = \alpha_1(y_t/\theta_{t-s}) + (1 - \alpha_1)a_{t-1}r_{t-1}$$


$$r_t = \alpha_2(a_t/a_{t-1}) + (1 - \alpha_2)r_{t-1}$$

$$\theta_t = \alpha_3(y_t/a_t) + (1 - \alpha_3)\theta_{t-s},$$

где  $\alpha_1, \alpha_2, \alpha_3$  - параметры сглаживания.

# МОДЕЛИ С ТРЕНДОМ И СЕЗОННОСТЬЮ

Модель Уинтерса с линейным трендом (модель Хольта-Уинтерса)



# ПРАКТИКА-4

- Простое экспоненциальное сглаживание
- Модели Хольта-Винтерса